

Do text-to-image models build a 3D model of a world inside? Simple use case with shadows generation

Zaawansowane zagadnienia sieci neuronowych

Dokumentacja końcowa

Natalia Choszczyk | Filip Langiewicz

nr indeksu 327267 | nr indeksu 327293

Politechnika Warszawska

Wydział Elektroniki i Technik Informacyjnych

6 czerwca 2026 r.

Spis treści

1. Wstęp i cel projektu	4
1.1. Kontekst i motywacja	4
2. Analiza problemu	6
2.1. Hipoteza badawcza	6
2.2. Scenariusze i oczekiwane wyniki	6
2.3. Kluczowe wyzwania	7
3. Przegląd literatury	8
3.1. Reprezentacje wewnętrzne modeli dyfuzyjnych	8
3.2. Świadomość 3D w modelach wizyjnych	8
3.3. Liniowe sondy jako narzędzie analizy	8
3.4. Architektura modelu SANA	9
4. Zbiór danych	10
4.1. Generowanie danych	10
4.2. Parametry zbioru danych	11
4.3. Struktura danych JSON	12
4.4. Podział zbioru danych	13
5. Metodologia	14
5.1. Ekstrakcja aktywacji modelu SANA-1.6B	14
5.2. Redukcja wymiarowości PCA	14
5.3. Sonda liniowa – Ridge Regression	15
5.3.1. Reprezentacja cykliczna azymutu	15
5.3.2. Trening	15
5.4. Metryki oceny	15
5.4.1. MAE azymutu (cykliczny)	15
5.4.2. MAE wysokości	16
5.4.3. Combined score	16
5.5. Punkty odniesienia	16

6. Eksperymenty i wyniki	17
6.1. Wyniki sondy na zbiorze testowym	17
6.2. Analiza generalizacji i wybór konfiguracji	18
6.3. Porównanie z punktami odniesienia	22
6.4. Wizualizacje predykcji	24
7. Interpretacja wyników	27
8. Wnioski	28
9. Wykorzystane technologie	29

1. Wstęp i cel projektu

Nowoczesne modele generatywne typu tekst-obraz potrafią tworzyć realistyczne obrazy zawierające spójne oświetlenie, cienie i głębię przestrzenną. Otwartym pytaniem pozostaje jednak, czy modele te dysponują wewnętrzną reprezentacją trójwymiarowej przestrzeni wraz z rządzącymi nią prawami fizyki, czy też jedynie odwzorowują wyuczone wzorce teksturowe w przestrzeni dwuwymiarowej. Pytanie to ma bezpośrednie implikacje dla rozumienia mechanizmów działania modeli generatywnych i ich zdolności do rozumowania przestrzennego.

Pośród dostępnych modeli tej klasy, takich jak Stable Diffusion czy FLUX, w projekcie został wykorzystany model SANA-1.6B [2]. Jest to model oparty na architekturze liniowego Diffusion Transformer (DiT), opracowany przez NVIDIA i MIT. Kluczowym uzasadnieniem tego wyboru jest wyjątkowo korzystny stosunek szybkości inferencji do jakości generowanych obrazów: SANA-1.6B osiąga wyniki porównywalne z modelem FLUX-dev na benchmarku DPG-Bench, przy znacznie wyższej przepustowości. Umożliwia to przeprowadzenie ekstrakcji aktywacji dla dużej liczby obrazów w rozsądnym czasie obliczeniowym. Ponadto model jest publicznie dostępny za pośrednictwem biblioteki `diffusers` i może być uruchomiony na standardowych kartach GPU, co upraszcza konfigurację środowiska.

Celem projektu jest empiryczna weryfikacja hipotezy o wewnętrznej reprezentacji 3D z wykorzystaniem analizy mechanistycznej (*mechanistic interpretability*) aktywacji modelu SANA. Zakłada się, że prosta liniowa sonda wytrenowana na zamrożonych aktywacjach pośrednich warstw modelu będzie w stanie przewidywać kierunek źródła światła oraz uogólniać tę predykcję na obiekty nieobecne w zbiorze treningowym.

1.1. Kontekst i motywacja

Jednym z centralnych pytań w analizie mechanistycznej modeli generatywnych jest to, w jakim stopniu ich wewnętrzne reprezentacje odpowiadają strukturze fizycznego świata, a nie jedynie statystycznym wzorcom w danych treningowych. Modele dyfuzyjne trenowane są na miliardach par obraz-tekst bez żadnych jawnie podanych szczegółów dotyczących informacji 3D – mimo to generują obrazy z zachowaną spójnością oświetlenia, perspektywy i cieni.

1.1. KONTEKST I MOTYWACJA

Wcześniejsze badania [3, 4] wykazały, że aktywacje modeli dyfuzyjnych kodują informacje o głębokości i normalnych powierzchni. Niniejszy projekt uzupełnia ten obraz o aspekt kierunku oświetlenia: czy model „wie”, skąd pada światło? Podejście eksperymentalne oparte na liniowych sondach [6] pozwala odpowiedzieć na to pytanie bez ingerencji w wagi modelu – wystarczy zbadać liniową separowalność interesującej cechy w przestrzeni aktywacji.

2. Analiza problemu

2.1. Hipoteza badawcza

Przyjęta hipoteza zakłada, że modele dyfuzyjne w trakcie procesu odsumiania (*denoising*) zapisują w swoich aktywacjach informacje o pewnych cechach fizycznych, takich jak kierunek oświetlenia, a nie tylko dopasowują wzorce tekstur. Oznacza to, że informacje o kącie padania światła mogą być obecne w aktywacjach warstw pośrednich modelu i są **liniowo dekodowalne** za pomocą prostej sondy regresyjnej.

Weryfikacja hipotezy opiera się na metodologii mechanistic interpretability: zamrożone aktywacje transformera są wejściem do regresji Ridge, a jakość predykcji kątów azymutu i wysokości lampy jest miarą tego, jak jawnie dana reprezentacja koduje kierunek oświetlenia. Kluczowym testem jest generalizacja na kształty niewidziane podczas treningu: jeśli sonda nauczyła się rzeczywistej właściwości fizycznej sceny (a nie cech specyficznych dla kształtu), powinna osiągać porównywalny błąd na sześcianach w porównaniu do walców i kul.

2.2. Scenariusze i oczekiwane wyniki

W tabeli 2.1 przedstawiono dwa możliwe scenariusze oraz ich oczekiwany wpływ na jakość predykcji liniowej sondy.

Tabela 2.1: Dwa scenariusze i oczekiwane wyniki sondy liniowej

Scenariusz	Interpretacja	Oczekiwany wynik sondy
Model zawiera reprezentację zależności fizycznych w przestrzeni 3D	Aktywacje zawierają reprezentację kąta oświetlenia	Niska wartość MAE, dobra generalizacja
Model zapamiętuje jedynie wzorce teksturalne w przestrzeni 2D	Aktywacje kodują wzorce pikseli, nie fizyczne zależności	Wysoki błąd, brak generalizacji na nowe obiekty

2.3. Kluczowe wyzwania

Realizacja projektu wiązała się z następującymi wyzwaniami technicznymi:

- **Polisemantyczność neuronów:** większość neuronów koduje jednocześnie wiele cech (kształt, kolor, materiał, oświetlenie), co utrudnia izolację informacji dotyczącej wyłącznie kierunku światła.
- **Cykliczność azymutu:** kąt 0° i 360° są identyczne, co wymaga zastosowania specjalnej reprezentacji (pary $(\sin \phi, \cos \phi)$) przy uczeniu regresji.
- **Wybór warstwy:** różne warstwy architektury modelu mogą kodować informacje na odmiennych poziomach abstrakcji; optymalną warstwę należy wybrać eksperymentalnie.
- **Krok czasowy odsumiania:** aktywacje zmieniają się w trakcie procesu *denoising*, dlatego konieczne jest wybranie reprezentatywnych kroków czasowych.

3. Przegląd literatury

3.1. Reprezentacje wewnętrzne modeli dyfuzyjnych

Chen et al. [3] wykazali, że aktywacje modelu Stable Diffusion kodują informacje o głębokości sceny i segmentacji semantycznej – możliwe jest ich odczytanie za pomocą prostej sondy liniowej. Niniejszy projekt rozszerza to podejście na analizę reprezentacji oświetlenia.

Surkov et al. [5] przeanalizowali model SDXL Turbo i wykazali, że poszczególne warstwy transformera wyspecjalizowały się w różnych aspektach obrazu: kompozycji, detalach oraz kolorze i oświetleniu. Potwierdza to, że informacja o oświetleniu jest obecna i lokalizowalna w konkretnych warstwach modelu.

3.2. Świadomość 3D w modelach wizyjnych

Banani et al. [4] zbadali, czy modele wizyjne (w tym Stable Diffusion) posiadają wewnętrzną reprezentację przestrzeni 3D. Używając sond liniowych do predykcji głębokości i normalnych powierzchni, wykazali, że modele dyfuzyjne kodują bogatsze informacje 3D niż modele dyskryminatywne. Metodologia i podział datasetu według kategorii obiektów zastosowane w tej pracy stanowią wzorzec dla niniejszego projektu.

3.3. Liniowe sondy jako narzędzie analizy

Alain i Bengio [6] zaproponowali metodę sond liniowych do badania wewnętrznych reprezentacji sieci neuronowych. Kluczowe założenie jest proste: jeśli informacja jest liniowo dekodowalna z aktywacji danej warstwy, to jest w niej jawnie zakodowana. Metoda ta pozwala odróżnić rzeczywiste kodowanie zmiennych fizycznych od przypadkowej korelacji z wzorcami teksturowymi.

3.4. Architektura modelu SANA

Xie et al. [2] przedstawiają SANA jako efektywny model dyfuzyjny oparty na liniowym Diffusion Transformerze (Linear DiT). Model wykorzystuje głęboki autoenkoder DC-AE kompresujący obraz $32\times$, co znacznie przyspiesza inferencję. SANA-0.6B jest ponad $100\times$ szybszy od FLUX-12B przy porównywalnej jakości na benchmarku DPG-Bench. W projekcie wykorzystana zostaje wersja SANA-1.6B oferująca wyższą jakość generowania.

4. Zbiór danych

4.1. Generowanie danych

Zbiór danych został wygenerowany za pomocą zmodyfikowanego skryptu `render_images.py` z repozytorium CLEVR [1], uruchomionego w środowisku Blender 2.78c z silnikiem renderowania Cycles (path tracing). Wprowadzono następujące modyfikacje względem oryginalnego zestawu narzędzi CLEVR:

- **Kontrola oświetlenia:** dodano argumenty `-light_azimuth` oraz `-light_elevation` umożliwiające precyzyjne pozycjonowanie lampy głównej (`Lamp_Key`) w układzie sferycznym. Pozycja lampy wyznaczana jest wzorami:

$$x = r \cos(\theta) \cos(\phi), \quad (4.1)$$

$$y = r \cos(\theta) \sin(\phi), \quad (4.2)$$


$$z = r \sin(\theta), \quad (4.3)$$

gdzie ϕ oznacza azymut, θ elewację, a $r = 5,0$ jest promieniem klosza.

- **Wyłączenie świateł pomocniczych:** lampy `Lamp_Fill` i `Lamp_Back` zostały ukryte (`hide_render = True`), aby usunąć wpływ innych lamp na generowanie cienia.
- **Jeden obiekt na scenę:** eliminuje interakcje cieni między wieloma obiektami.
- **Wymuszony kolor i materiał:** wszystkie obiekty mają kolor fioletowy (`purple`) i materiał `rubber`, co eliminuje kolor jako zmienną zakłócającą. Wybrany niemetaliczny materiał zmniejsza problem związany z odbijaniem światła lampy na powierzchniach przedmiotów, co w niektórych przypadkach tworzyło rozległe białe plamy mogące zakłócić przebieg eksperymentu.

Na Rysunku 4.1 przedstawiono definicję kątów azymutu i wysokości wykorzystywanych w układzie sferycznym sceny.

4.2. PARAMETRY ZBIORU DANYCH



Rysunek 4.1: Definicja kątów azymutu i wysokości w układzie sferycznym


4.2. Parametry zbioru danych

Poniższa tabela 4.1 przedstawia parametry generowanego przez nas zbioru danych. Wysokość lampy została ograniczona do zakresu $\mathcal{U}(30^\circ, 75^\circ)$, ponieważ przy skrajnych wartościach kątów na powierzchni tła pojawiały się zbyt duże plamy światła albo generowany cień był niewidoczny.


Tabela 4.1: Parametry generowanego zbioru danych

Parametr	Wartość
Rozdzielczość	512×512 px
Próbkowanie	64 próbki/obraz
Azymut	losowy z $\mathcal{U}(0^\circ, 360^\circ)$
Wysokość	losowa z $\mathcal{U}(30^\circ, 75^\circ)$
Liczba obrazów	1000 na każdą bryłę
Kształty	SmoothCube_v2, Sphere, SmoothCylinder
Kolor / materiał	fioletowy / rubber
Format pliku	PNG + JSON (metadane)


Przykładowe obrazy z wygenerowanego zbioru danych przedstawiono na Rysunku 4.2. Widoczne są trzy typy brył (walec, kula, sześcian) wygenerowane zmodyfikowanym skryptem.



(a) Sześcian



(b) Kula



(c) Walec

Rysunek 4.2: Przykładowe obrazy ze zbioru danych dla każdej z trzech brył

4.3. Struktura danych JSON

Każdemu obrazowi towarzyszy plik JSON zawierający m.in.:

```
{
  "light_azimuth_deg": 101.7,
  "light_elevation_deg": 45.0,
  "objects": [{
    "shape": "cube",
    "3d_coords": [1.795, 0.410, 1.0],
    "pixel_coords": [339, 232, 9.97],
    "color": "purple",
    "material": "rubber",
    "rotation": 215.9
  }]
}
```

Pola `pixel_coords` (pozycja piksela obiektu obliczona przez Blendera) oraz `3d_coords` (pozycja 3D obiektu w scenie) okazały się przydatne przy wizualizacji predykcji – umożliwiając geometrycznie poprawne rysowanie strzałek kierunku oświetlenia.

4.4. Podział zbioru danych

Podział oparty na kształcie (a nie losowy) pozwala ocenić zdolność sondy do generalizacji na obiekty nieobecne podczas treningu, co stanowi kluczowy test hipotezy badawczej. Z tego powodu postanowiono zdecydować się na podział danych taki jak przedstawiony w tabeli 4.2.

Tabela 4.2: Podział zbioru danych według kształtu obiektów

Podzbiór	Kształty	Liczba obrazów	Udział	Cel
Treningowy	walce, kule	1600	80%	uczenie sondy
Walidacyjny	walce, kule	200	10%	dobór hiperparametrów
Testowy (<code>test</code>)	walce, kule	200	10%	ewaluacja ogólna
<code>test_cubes</code>	sześciany	1000	osobny	test generalizacji

5. Metodologia

5.1. Ekstrakcja aktywacji modelu SANA-1.6B

Model SANA-1.6B (`Efficient-Large-Model/Sana_1600M_1024px_BF16_diffusers`) załadowano przez bibliotekę HuggingFace `diffusers` w trybie `bfloat16` (niezbędne dla uniknięcia wartości NaN). Dla każdego obrazu przeprowadzono następujące kroki:

1. Obraz przeskalowano do rozdzielczości 1024×1024 px i zakodowano do przestrzeni latentnej autoenkodera DC-AE z kompresją $\times 32$.
2. Do reprezentacji latentnej dodano szum gaussowski odpowiadający wybranemu krokowi czasowemu t .
3. Wykonano forward pass przez transformer, przechwytyując aktywacje wybranych bloków za pomocą *forward hooks*.

Testowane kombinacje obejmowały 3 warstwy (`layer_04`, `layer_10`, `layer_18`, odpowiadające blokom `transformer_blocks.4/10/18`) oraz 3 kroki czasowe ($t \in \{200, 500, 800\}$), dając łącznie 9 konfiguracji. Ekstrakcja realizowana była jako SLURM array job z rozmiarem chunka 300 obrazów na zadanie.

5.2. Redukcja wymiarowości PCA

Aktywacje bloku transformera mają kształt $(1, 1024, 2240)$ – odpowiednio: batch, tokeny przestrzenne i wymiar cechy. Przed spłaszczeniem zastosowano **average pooling** 4×4 : przestrzenna siatka 32×32 tokenów zredukowana jest do 8×8 , co daje wektor $(8 \times 8 \times 2240) = 143\,360$ cech. Wybór 4×4 (a nie np. globalnego average pooling) jest kompromisem: zachowuje lokalizację przestrzenną (istotną dla asymetrii oświetlenia), jednocześnie redukując wymiarowość 16-krotnie względem pełnej siatki. Globalne pooling straciłoby informację przestrzenną potrzebną do odróżnienia, po której stronie obiektu pada światło.

Ze względu dalej wysoką wymiarowość aktywacji (143 360 cech) zastosowano dalszą redukcję *Incremental PCA* do 256 komponentów (`pca256`) przed trenowaniem sondy. Redukcja dopasowywana była wyłącznie na zbiorze treningowym (`IncrementalPCA` z `batch_size=600`), co zapobiega wyciekowi informacji z danych walidacyjnych i testowych. Testowano trzy wartości $n_{PCA} \in \{256, 512, 1024\}$. Wyboru dokonano na podstawie MAE na zbiorze walidacyjnym oraz szybkości przeprowadzanych obliczeń. Konfiguracja $n_{PCA} = 256$ została dobrana eksperymentalnie i była kompromisem pomiędzy szybkością, a zachowaniem większości wariancji zbioru.

5.3. Sonda liniowa – Ridge Regression

5.3.1. Reprezentacja cykliczna azymutu

Azymut ϕ jest kątem cyklicznym w zakresie $[0^\circ, 360^\circ)$, co uniemożliwia bezpośrednią regresję (błąd modelu pomiędzy 1° a 359° powinien wynosić 2° , nie 358°). Zastosowano zatem reprezentację trygonometryczną

$$\mathbf{y} = [\sin(\phi), \cos(\phi), \theta], \quad (5.1)$$

gdzie θ oznacza wysokość w stopniach. Predykcja azymutu odbywa się przez

$$\hat{\phi} = \text{atan2}(\hat{s}, \hat{c}) \mod 360^\circ, \quad (5.2)$$

gdzie $\hat{s}$ i $\hat{c}$ są predykcjami komponentów $\sin$ i $\cos$.

5.3.2. Trening

Regresja Ridge z parametrem regularyzacji $\alpha = 1,0$ (również dobrany eksperymentalnie na podstawie wyników na zbiorze walidacyjnym) trenowana była osobno dla każdej z 9 konfiguracji warstwa $\times$ timestep.

5.4. Metryki oceny

Dla każdej predykcji porównuje się przewidziany kąt z wartością zapisaną w pliku JSON. Podstawową miarą błędu jest MAE (*Mean Absolute Error*) wyrażone w stopniach.

5.4.1. MAE azymutu (cykliczny)

Dla azymutu (kąt poziomy, cykliczny $0^\circ - 360^\circ$)

$$\text{MAE}_\phi = \frac{1}{N} \sum_{i=1}^N \min(|\hat{\phi}_i - \phi_i|, 360^\circ - |\hat{\phi}_i - \phi_i|) \quad (5.3)$$

5.4.2. MAE wysokości

Dla wysokości (kąt pionowy)

$$\text{MAE}_\theta = \frac{1}{N} \sum_{i=1}^N |\hat{\theta}_i - \theta_i| \quad (5.4)$$

5.4.3. Combined score

Aby porównywać konfiguracje w jednej metryce uwzględniającej oba kąty przy ich różnych zakresach (azymut: 360° , elewacja: 45°), zdefiniowano znormalizowany *combined score*

$$S = \frac{\text{MAE}_\phi}{360^\circ} + \frac{\text{MAE}_\theta}{45^\circ} \quad (5.5)$$

5.5. Punkty odniesienia

Przed oceną wyników sondy ustalono trzy poziomy odniesienia odzwierciedlające jakość predykcji bez wykorzystania modelu, opisane w tabeli 5.1.

Tabela 5.1: Punkty odniesienia dla kątów

Baseline	Opis
Losowy	Przewidywanie losowego kąta
Zawsze średnia	Przewidywanie średniej kąta ze zbioru treningowego
Sonda na aktywacjach	Cel projektu - regresja na aktywacjach SANA

Wynik sondy na aktywacjach przekraczający punkty odniesienia stanowi dowód na to, że model koduje informację o oświetleniu.

6. Eksperymenty i wyniki

6.1. Wyniki sondy na zbiorze testowym

Tabela 6.1 zawiera wyniki ewaluacji dla wszystkich 9 konfiguracji (warstwa $\times$ krok czasowy) na zbiorze `test` złożonym z walców i kul – kształtów, na których sonda była trenowana. Każda konfiguracja to niezależnie wytrenowana sonda Ridge z redukcją PCA256.

Tabela 6.1: Wyniki sondy na zbiorze `test` (walce i kule)

Warstwa	Timestep	MAE az ($^{\circ}$)	MAE el ($^{\circ}$)
layer_04	t_200	14,33	7,13
layer_04	t_500	15,20	7,02
layer_04	t_800	19,16	6,57
layer_10	t_200	13,01	6,88
layer_10	t_500	15,27	7,98
layer_10	t_800	14,87	6,03
layer_18	t_200	13,42	7,08
layer_18	t_500	14,67	8,03
layer_18	t_800	18,27	6,61

Najniższy MAE azymutu osiągnęła konfiguracja **layer_10 / t_200** ($13,01^{\circ}$), a najniższy MAE wysokości – **layer_10 / t_800** ($6,03^{\circ}$). Widoczna tendencja to pogorszenie predykcji azymutu przy rosnącym kroku czasowym dla warstw skrajnych (**layer_04**, **layer_18**), natomiast warstwa środkowa **layer_10** utrzymuje relatywnie stabilną jakość w obu metrykach. Wyniki potwierdzają, że sonda liniowa jest w stanie odczytać informację o kierunku oświetlenia z zamrożonych aktywacji transformera.

6.2. Analiza generalizacji i wybór konfiguracji


Kluczowym pytaniem eksperymentu jest, czy zakodowana informacja jest niezmiennicza na kształt obiektu – tj. czy sonda wytrenowana na walcach i kulach poradzi sobie równie dobrze na niewidzianych sześcianach (`test_cubes`). Tabela 6.2 zestawia wyniki dla wszystkich 9 konfiguracji na zbiorze `test_cubes` (1000 sześcianów SmoothCube_v2) wraz z różnicą generalizacji (*gap*) względem `test`.

Tabela 6.2: Wyniki sondy na zbiorze `test_cubes` wraz z różnicą generalizacji ($\Delta = \text{cubes} - \text{test}$)


Warstwa	Timestep	Az_{cubes}	El_{cubes}	Δaz	Δel	Score
layer_04	t_200	14,19	7,42	$-0,14^\circ$	$+0,29^\circ$	0,2043
layer_04	t_500	15,65	7,15	$+0,45^\circ$	$+0,13^\circ$	0,2024
layer_04	t_800	19,03	7,07	$-0,13^\circ$	$+0,50^\circ$	0,2101
layer_10	t_200	14,01	6,94	$+0,99^\circ$	$+0,06^\circ$	0,1931
layer_10	t_500	15,27	7,56	$-0,01^\circ$	$-0,42^\circ$	0,2105
layer_10	t_800	16,82	6,14	$+1,96^\circ$	$+0,11^\circ$	0,1832
layer_18	t_200	14,84	6,87	$+1,41^\circ$	$-0,21^\circ$	0,1939
layer_18	t_500	14,88	7,79	$+0,21^\circ$	$-0,24^\circ$	0,2146
layer_18	t_800	17,65	6,42	$-0,61^\circ$	$-0,18^\circ$	0,1918

Heatmapy MAE azymutu, elewacji oraz *combined score* przedstawiono na Rysunkach 6.1–6.3. Warstwa środkowa `layer_10` dominuje w kolumnie `t_200`, osiągając najniższe MAE azymutu ($14,01^\circ$), natomiast przy `t_800` przewagę (niewielką) przejmuje kryterium wysokości.


6.2. ANALIZA GENERALIZACJI I WYBÓR KONFIGURACJI



Rysunek 6.1: Heatmapa MAE azymutu na zbiorze `test_cubes` (oś X: timestep, oś Y: warstwa)




Rysunek 6.2: Heatmapa MAE wysokości na zbiorze `test_cubes`




Rysunek 6.3: Heatmapa *combined score* S (5.5) na zbiorze `test_cubes`

Heatmapy różnicy generalizacji (Rysunki 6.4–6.5) pokazują, że różnica MAE między `test_cubes`

a `test` jest bliska zero dla niemal wszystkich konfiguracji – zarówno dla azymutu, jak i wysokości. Brak wyraźnego wzorca przestrzennego na obu heatmapach świadczy o tym, że degradacja nie jest specyficzna dla żadnej warstwy ani kroku czasowego, lecz stanowi szum pomiarowy rzędu $\pm 2^\circ$.




Rysunek 6.4: Heatmapa *gap* generalizacji dla MAE azymutu (cubes — test). Wartości bliskie zero świadczą o braku degradacji na niewidzianych kształtach.



Rysunek 6.5: Heatmapa *gap* generalizacji dla MAE wysokości (cubes — test)


Rysunek 6.6 przedstawia zależność MAE azymutu od MAE elewacji dla każdej z 9 konfiguracji. Widoczny jest trade-off między obiema metrykami – konfiguracje z niskim błędem azymutu (lewy obszar wykresu) mają tendencję do wyższego błędu dla wysokości i odwrotnie. Żadna konfiguracja nie dominuje jednocześnie w obu wymiarach.

6.2. ANALIZA GENERALIZACJI I WYBÓR KONFIGURACJI



Rysunek 6.6: MAE azymutu vs. MAE wysokości na `test_cubes` dla 9 konfiguracji

Wykres na rysunku 6.7 porządkuje konfiguracje rosnąco według *combined score*. Konfiguracja `layer_10 / t_800` zajmuje pierwszą pozycję ($S = 0,1832$), jednak dystans do kolejnych – `layer_18 / t_800` ($S = 0,1918$) i `layer_10 / t_200` ($S = 0,1931$) – jest niewielki.



Rysunek 6.7: Barplot *combined score* posortowany rosnąco dla 9 konfiguracji na `test_cubes`

Ogólne tendencje

Wyższy krok czasowy ($t = 800$) pogarsza predykcję azymutu przy warstwach skrajnych (`layer_04`, `layer_18`), lecz poprawia predykcję wysokości w warstwie środkowej (`layer_10`). Kluczową obserwacją jest również, że *gap* generalizacji jest bliski zeru dla wszystkich konfiguracji: maksymalna różnica

generalizacji dla azymutu wynosi $+1,96^\circ$ (**layer_10/t_800**), a wiele konfiguracji wykazuje ujemną różnicę – sonda działa *lepiej* na niewidzianych sześcianach niż na kształtach treningowych.

Wybór konfiguracji finalnej

Najlepszym *combined score* na sześcianach wyróżnia się **layer_10 / t_800** ($S = 0,1832$), jednak jako konfigurację finalną wybrano **layer_10 / t_200** z następujących powodów:

1. **Najniższy MAE azymutu** – zarówno na zbiorze **test** ($13,01^\circ$), jak i na **test_cubes** ($14,01^\circ$), co czyni ją bezwzględnie najlepszą konfiguracją w najważniejszej metryce. Azymut jest trudniejszą i diagnostycznie istotniejszą wielkością (360° vs ograniczony zakres wysokości).
2. **Mniejsza różnica przeuczenia** – *gap* azymutu dla **layer_10/t_200** wynosi $+0,99^\circ$, podczas gdy dla **layer_10/t_800** – $+1,96^\circ$, co oznacza dwukrotnie gorsze przeuczenie mimo lepszego *combined score*.
3. **Przewaga *combined score* jest marginalna** – różnica między **layer_10/t_800** ($0,1832$) a **layer_10/t_200** ($0,1931$) wynika wyłącznie z niższego MAE wysokości przy $t = 800$, lecz konfiguracja $t = 800$ osiąga to kosztem wyraźnie gorszego azymutu na sześcianach ($16,82^\circ$ vs $14,01^\circ$).

Konfiguracja **layer_10 / t_200** stanowi zatem najlepszy kompromis między jakością predykcji azymutu, odpornością na przeuczenie i generalizacją na niewidziane kształty.

6.3. Porównanie z punktami odniesienia

Tabela 6.3 zestawia wynik wybranej konfiguracji z dwoma deterministycznymi punktami odniesienia, wyznaczonymi na zbiorze **test_cubes** (1000 sześcianów).


Tabela 6.3: Porównanie sondy z punktami odniesienia dla konfiguracji **layer_10 / t_200** na zbiorze **test_cubes**

Metoda	MAE az ($^\circ$)	MAE el ($^\circ$)	Opis
Baseline: losowy	89,86	14,61	$\phi \sim \mathcal{U}(0^\circ, 360^\circ)$
Baseline: zawsze średnia	88,87	11,35	stała predykcja = średnia treningowa
Sonda (Ridge + PCA256)	14,01	6,94	aktywacje layer_10 / t_200
Poprawa vs losowy	$+75,85^\circ$	$+7,67^\circ$	
Poprawa vs zawsze średnia	$+74,86^\circ$	$+4,41^\circ$	

Sonda osiąga blisko 6-krotną redukcję MAE azymutu względem predykcji losowej ($14,01^\circ$ vs $89,86^\circ$) i porównywalną poprawę względem baseline'u przewidywania zawsze średniej. Mediana błędu azymutu wynosi zaledwie $10,15^\circ$, a percentyl 90. – $30,72^\circ$, co oznacza, że dla 9 na 10 sześcianów sonda myli się o mniej niż 31° . Fakt, że prosta sonda liniowa wytrenowana na zamrożonych aktywacjach bez żadnego fine-tuningu osiąga tak wyraźną przewagę, stanowi silny dowód na to, że model SANA koduje informację o kierunku oświetlenia w swoich reprezentacjach wewnętrznych ponad poziom wynikający z przypadku.

Rysunek 6.8 przedstawia rozkład bezwzględnych błędów azymutu i wysokości kąta oświetlenia na 1000 sześcianach. Rozkład błędów azymutu jest silnie prawostronnie skośny – ponad połowa próbek mieści się poniżej mediany $10,2^\circ$, a długi ogon sięgający $\sim 120^\circ$ odpowiada trudnym przypadkom przy wysokim kącie pionowym lampy, gdzie cień jest słabym sygnałem kierunkowym.

Rozkład błędów wysokości jest prawostronnie skośny ze szczytem przy małych wartościach – ponad połowa sześcianów ma błąd poniżej mediany $6,2^\circ$, a błędy powyżej 20° są sporadyczne. Świadczy to o tym, że kąt pionowy oświetlenia jest przez sondę dekodowany stabilnie dla zdecydowanej większości przypadków, a nieliczne duże błędy odpowiadają skrajnym geometriom sceny.




Rysunek 6.8: Rozkład błędów bezwzględnych azymutu i wysokości sondy na zbiorze `test_cubes` (konfiguracja `layer_10 / t_200`). Pionowe linie oznaczają wartości MAE i mediany.

Rysunek 6.9 pokazuje zależność predykcji sondy od wartości rzeczywistych dla obu zmiennych. Punkty dla azymutu układają się ściśle wzdłuż przekątnej $y = x$ w całym zakresie 0° – 360° , co świadczy o tym, że sonda poprawnie odwzorowuje cykliczny charakter zmiennej i nie wykazuje systematycznego obciążenia w żadnym regionie kątowym. Skupienia obserwacji w lewym górnym i prawym dolnym rogu wykresu wynikają jedynie z cykliczności azymutu oświetlenia.

Wykres wysokości ujawnia systematyczne odchylenie od idealnej predykcji: sonda zawyża wartości przy niskich kątach ($\sim 30^\circ$ – 45°) i zaniża przy wysokich ($> 60^\circ$). Oznacza to, że zakodowana reprezentacja wysokości w aktywacjach jest liniowo skorelowana z wartością rzeczywistą, lecz skompresowana

względem pełnego zakresu – sonda *wie* o kierunku oświetlenia, ale nie odwzorowuje skrajnych wartości z pełną dokładnością.




Rysunek 6.9: Wykres predykcji vs. wartości rzeczywistych dla azymutu (lewy) i wysokości (prawy) na zbiorze `test_cubes`. Idealna predykcja leżałaby na przekątnej $y = x$.

6.4. Wizualizacje predykcji


Ponieważ kierunek cienia zależy od wzajemnego położenia lampy i obiektu w scenie, przy generacji datasetu zapisywano trójwymiarową pozycję źródła światła, co pozwoliło wyznaczać ground truth kierunku cienia geometrycznie i nanosić go na obraz jako strzałkę. Predykcje modelu liniowego przedstawiono na wizualizacjach, gdzie pokazane są obiekty oraz nałożone na rysunek dwie strzałki wychodzące z pozycji pikselowej obiektu: zielona (ground truth) i czerwona (predykcja sondy).

Na Rysunkach 6.10–6.11 przedstawiono przykłady z zestawu `test` (kule i walce), a na Rysunkach 6.12–6.13 – z zestawu `test_cubes` (sześciiany).


6.4. WIZUALIZACJE PREDYKCJI




Rysunek 6.10: Przykłady trafnych predykcji na zbiorze `test`: kula (lewy) i walec (prawy) z małym błędem azymutu. Zielona strzałka: ground truth, czerwona: predykcja sondy.



Rysunek 6.11: Przykłady błędnych predykcji na zbiorze `test`: kula (lewy, błąd $41,5^\circ$) i walec (prawy, błąd $142,1^\circ$).



Rysunek 6.12: Przykłady trafnych predykcji na zbiorze `test_cubes` z błędem azymutu $\approx 0,0^\circ$.



Rysunek 6.13: Przykłady błędnych predykcji na zbiorze `test_cubes` z błędem azymutu $> 115^\circ$.

7. Interpretacja wyników

Wyniki eksperymentów jednoznacznie potwierdzają, że kierunek oświetlenia jest liniowo dekodowalny z aktywacji pośrednich warstw modelu SANA-1.6B. Sonda Ridge wytrenowana na zaledwie 256 głównych składowych aktywacji uzyskuje MAE azymutu rzędu $13\text{--}15^\circ$ na zbiorze testowym – przy zakresie 360° oznacza to błąd względny zaledwie $3,6\text{--}4,2\%$ – co stanowi blisko 6-krotną poprawę względem baseline’u losowego ($\approx 90^\circ$). Fakt, że tak prosta para PCA256 + Ridge w ogóle działa, jest sam w sobie dowodem na to, że informacja o oświetleniu jest obecna w aktywacjach w sposób globalny i skondensowany – nie rozproszony po tysiącach wymiarów, lecz uchwytany przez liniową projekcję na podprzestrzeń o wymiarze 256.

Generalizacja na sześciany wykazuje minimalną różnicę predykcji względem zbioru treningowego: MAE azymutu wzrasta o co najwyżej $+1,96^\circ$, a MAE wysokości kąta oświetlenia pozostaje praktycznie niezmienione. Świadczy to o tym, że sonda dekoduje fizyczną właściwość sceny niezależną od geometrii obiektu, a nie cechę specyficzną dla kształtów widzianych podczas treningu. Jest to spójne z tezą Banani et al. [4], że modele dyfuzyjne kodują bogatsze cechy 3D niż modele dyskryminatywne.

Najlepsze wyniki uzyskują warstwy środkowe (`layer_10`) przy niskim kroku czasowym ($t = 200$): przy małym szumie model dysponuje już spójną reprezentacją treści obrazu, a warstwa środkowa balansuje między cechami lokalnymi a semantyką globalną. Aktywacje warstw wczesnych przy $t = 800$ są zdominowane przez szum, co tłumaczy wyraźnie gorszy wynik `layer_04/t_800` ($19,16^\circ$).

Ograniczeniem pracy jest polisemantyczność aktywacji: każda warstwa koduje jednocześnie wiele cech sceny, a sonda liniowa wyciąga kierunek oświetlenia jako ich kombinację liniową, nie pozwalając zidentyfikować konkretnych neuronów odpowiedzialnych za to kodowanie. Dalsze badania z użyciem Sparse Autoencodera, analogicznie do [5], mogłyby precyzyjniej zlokalizować te reprezentacje i zweryfikować, czy są one interpretowalne w sensie fizycznym.

8. Wnioski

Przeprowadzone eksperymenty pozwalają na jednoznaczne potwierdzenie hipotezy badawczej: **model SANA-1.6B koduje kierunek oświetlenia w swoich aktywacjach pośrednich w sposób liniowo dostępny**.

Kluczowe obserwacje:

- Sonda liniowa (Ridge Regression) wytrenowana na aktywacjach z warstwy `layer_10` przy kroku $t = 200$ osiąga MAE azymutu $13,01^\circ$ na zbiorze testowym (walce, kule) i $14,01^\circ$ na zbiorze `test_cubes` – wobec $89,86^\circ$ dla baseline’u losowego, co daje poprawę $+75,85^\circ$.
- Różnica generalizacji na sześciany (niewidziane kształty) jest bliska zeru ($< 2^\circ$) dla wszystkich 9 konfiguracji, co potwierdza, że sonda dekoduje fizyczną właściwość sceny, nie cechę specyficzną dla geometrii obiektu.
- Dla przypadków przy dużym kącie zawieszenia lampy ($\theta > 60^\circ$), sonda nadal poprawnie przewiduje kierunek oświetlenia. Co więcej, kierunek cienia na podłodze zależy nie tylko od kąta oświetlenia, lecz również od bezwzględnej pozycji obiektu w scenie – ten sam azymut i wysokość lampy dają cień rzucony w różnych kierunkach na obrazie w zależności od tego, gdzie obiekt stoi. Fakt, że sonda działa poprawnie mimo tej niejednoznaczności, sugeruje, że model SANA koduje w swoich reprezentacjach zarówno kierunek oświetlenia, jak i pozycję obiektu w scenie – jest w stanie rozróżnić, czy obiekt jest bliżej czy dalej, po lewej czy prawej stronie, i uwzględnić to przy dekodowaniu kierunku lampy.
- Warianty PCA z 256 komponentami okazały się wystarczające – wzrost do 512 lub 1024 komponentów prowadził do przeuczenia (wyższy MAE na zbiorze walidacyjnym przy niższym MAE treningowym).

Odpowiedź na tytułowe pytanie projektu jest zatem twierdząca: modele generatywne tekst-obraz, nawet trenowane wyłącznie na obrazach 2D, rozwijają wewnętrzne reprezentacje zawierające informacje o fizycznych właściwościach trójwymiarowej sceny – przynajmniej w zakresie kierunku oświetlenia. Kierunek ten jest liniowo dostępny w aktywacjach pośrednich warstw, a informacja ta nie jest specyficzna dla kształtu obiektu, lecz stanowi uogólnioną reprezentację fizyczną.

9. Wykorzystane technologie

Projekt został wykonany przy użyciu technologii opisanych w tabeli 9.1. Praca powstała z wykorzystaniem zasobów w ramach grantu nr PLG/2025/019439.

Tabela 9.1: Zestawienie technologii wykorzystanych w projekcie

Technologia	Zastosowanie
Blender 2.78c	Renderowanie zbioru danych
Python 3.10+	Główny język projektu
PyTorch 2.x	Obsługa modelu dyfuzyjnego, ekstrakcja aktywacji
Hugging Face diffusers 0.27+	Ładowanie SANA-1.6B i forward pass
scikit-learn 1.x	Ridge Regression, IncrementalPCA, metryki
NumPy / SciPy	Obliczenia numeryczne, metryki kątowe
Matplotlib / Seaborn	Wizualizacje (heatmaps, scatter, barplot, strzałki)
Pillow (PIL)	Wczytywanie i modyfikacja obrazów
PowerShell 5.1	Automatyzacja renderowania (Windows)
Superkomputer Athena	Ekstrakcja aktywacji i trening sondy (GPU, SLURM)
SLURM	System kolejkowania zadań GPU (array jobs)
Git / GitHub	Kontrola wersji kodu i dokumentacji

Model SANA-1.6B wymaga około 16 GB pamięci VRAM [2], co pozwala na uruchomienie na infrastrukturze HPC superkomputera Athena.

Bibliografia

- [1] Johnson, J., Hariharan, B., van der Maaten, L., Fei-Fei, L., Zitnick, C. L., Girshick, R. (2017). *CLEVR: A Diagnostic Dataset for Compositional Language and Elementary Visual Reasoning*. CVPR 2017. arXiv:1612.06890. <https://arxiv.org/abs/1612.06890>
- [2] Xie, E., Chen, J., Chen, J., Cai, H., Tang, H., Lin, Y., Zhang, Z., Li, M., Zhu, L., Lu, Y., Han, S. (2024). *SANA: Efficient High-Resolution Image Synthesis with Linear Diffusion Transformers*. arXiv:2410.10629. <https://arxiv.org/abs/2410.10629>
- [3] Chen, Y., Viégas, F., Wattenberg, M. (2023). *Beyond Surface Statistics: Scene Representations in a Latent Diffusion Model*. NeurIPS 2023 Workshop on Diffusion Models. arXiv:2306.05720. <https://arxiv.org/abs/2306.05720>
- [4] Banani, M., Raj, A., Maninis, K., Kar, A., Li, Y., Rubinstein, M., Sun, D., Guibas, L., Johnson, J., Jampani, V. (2024). *Probing the 3D Awareness of Visual Foundation Models*. CVPR 2024. arXiv:2404.08636. <https://arxiv.org/abs/2404.08636>
- [5] Surkov, V., Wendler, C., Mari, A., Terekhov, M., Deschenaux, J., West, R., Gulcehre, C., Bau D. (2024). *One-Step is Enough: Sparse Autoencoders for Text-to-Image Diffusion Models*. arXiv:2410.22366. <https://arxiv.org/abs/2410.22366>
- [6] Alain, G., Bengio, Y. (2016). *Understanding intermediate layers using linear classifier probes*. arXiv:1610.01644. <https://arxiv.org/abs/1610.01644>